

FACULTAD DE INGENIERÍA Y CIENCIAS BÁSICAS

PROGRAMA ACADÉMICO: INGENIERÍA DE DATOS E INTELIGENCIA ARTIFICIAL

CURSO: ETL (G01)

PROYECTO ETL — INGENIERÍA DE DATOS PARA EL DESARROLLO SOSTENIBLE EN COLOMBIA

FASE 1: DE LOS REQUISITOS ANALÍTICOS A UN ALMACÉN DE DATOS DIMENSIONAL

1. OBJETIVO

Diseñar e implementar la primera etapa de una solución de datos analíticos para estudiar un problema colombiano específico asociado con un Objetivo de Desarrollo Sostenible (ODS). El proyecto debe demostrar coherencia entre la comprensión del problema, los requisitos analíticos, la selección y evaluación del conjunto de datos, el perfilado de datos, la preparación de datos, el modelado dimensional, el ETL, el Data Warehouse, SQL/KPI, Business Intelligence y la interpretación de los hallazgos para apoyar la toma de decisiones.

Perspectiva guía: Problema → Requisitos → Datos → ETL → Modelo Dimensional → Data Warehouse → KPI → BI → Apoyo a la toma de decisiones.

Esta es una primera implementación académica. El énfasis no está únicamente en programar scripts, sino en diseñar una solución analítica coherente cuyos componentes técnicos respondan a una necesidad claramente definida.

2. DEFINICIÓN DEL PROBLEMA COLOMBIANO

Cada equipo debe seleccionar un ODS e identificar un problema colombiano específico relacionado con él. El ODS proporciona el marco general; el problema colombiano concreto es el objeto de análisis. Delimite el problema geográfica, sectorialmente o por población cuando sea apropiado.

Ejemplo:

Formulación débil: Analizar el ODS 3 en Colombia.

Formulación mejorada: Analizar las desigualdades en el acceso a los servicios de salud entre los departamentos colombianos.

La definición del problema debe incluir:

1. ODS seleccionado.
2. Meta(s) relevante(s) del ODS, cuando corresponda.
3. Contexto colombiano y evidencia que motive el problema.
4. Alcance geográfico.
5. Población, sector o fenómeno de interés.
6. Planteamiento preciso del problema.
7. Posibles partes interesadas o usuarios de la solución analítica.
8. Relevancia del análisis para la toma de decisiones.

3. OBJETIVO Y REQUISITOS ANALÍTICOS

Defina un objetivo analítico/de negocio y al menos cinco requisitos analíticos, identificados como R1-R5. Cada requisito debe representar una necesidad analítica real, relacionarse directamente con el problema colombiano, poder responderse con el conjunto de datos seleccionado, apoyar una decisión o generar un conocimiento y requerir análisis, no una simple consulta de registros.

Distinción importante: un gráfico, KPI, consulta SQL o dashboard no es un requisito analítico. Estos son productos analíticos utilizados para satisfacer un requisito.

MATRIZ DE REQUISITOS (R1-R5)

ID | Requisito analítico | Pregunta de negocio | Decisión / conocimiento respaldado
R1
R2
R3
R4
R5

4. ALINEACIÓN CON LOS ODS

Justifique brevemente cómo el problema colombiano seleccionado y los requisitos analíticos se relacionan con el ODS elegido. Cuando sea pertinente, identifique las metas o indicadores asociados.

Alcance: El proyecto no necesita reproducir un indicador oficial de los ODS. Sin embargo, la relación entre el problema seleccionado y el ODS debe justificarse claramente.

5. SELECCIÓN DE LA FUENTE DE DATOS

Utilice una fuente de datos principal para esta entrega. El conjunto de datos debe estar directamente relacionado con el problema colombiano seleccionado y, preferiblemente, provenir de un gobierno colombiano oficial o una institución pública, como Datos Abiertos Colombia, DANE, DNP, un ministerio, una agencia nacional o un portal de datos abiertos departamental o municipal. Se pueden considerar otras fuentes cuando se justifique su relevancia y confiabilidad.

Las siguientes características deben utilizarse como pautas generales para seleccionar el conjunto de datos, no como umbrales inflexibles:

- Aproximadamente 10.000 registros o más.
- Al menos 8–10 atributos relevantes.
- Suficiente riqueza analítica para soportar R1–R5.
- Información temporal cuando corresponda.
- Atributos categóricos o descriptivos que puedan soportar dimensiones significativas.
- Información adecuada para hechos, medidas o KPI.
- Fuente, propietario de los datos y descripción del conjunto de datos claramente identificables.

Posible excepción: Se pueden aceptar conjuntos de datos más pequeños cuando su valor analítico, cobertura geográfica, profundidad temporal o relevancia para el problema justifiquen su uso.

6. EVALUACIÓN DE IDONEIDAD DEL CONJUNTO DE DATOS

Evalúe el conjunto de datos antes de la implementación y documente lo siguiente:

MATRIZ DE IDONEIDAD DEL CONJUNTO DE DATOS

Criterio | Evaluación
Institución / propietario de los datos
URL de la fuente / mecanismo de acceso
Formato
Número de registros
Número de atributos
Cobertura geográfica
Cobertura temporal
Medidas numéricas relevantes
Atributos categóricos relevantes
Posibles problemas de calidad de datos
Relación con los requisitos analíticos
Idoneidad para el modelado dimensional
Unidad de observación en la fuente

7. PERFILADO Y EVALUACIÓN DE LA CALIDAD DE LOS DATOS

Realice y documente un perfil inicial de los datos que incluya, como mínimo:

- Número de registros y atributos.
- Nombres de las columnas y tipos de datos.
- Valores faltantes y registros duplicados.
- Valores únicos y cardinalidad.
- Cobertura de fechas.
- Cobertura geográfica, cuando corresponda.
- Valores inválidos, inconsistentes o sospechosos.
- Rangos numéricos relevantes y estadísticas descriptivas básicas.
- Problemas que puedan afectar los requisitos o el modelo dimensional.

Propósito: El objetivo es comprender los datos e identificar problemas relevantes de calidad.

8. TRAZABILIDAD DE REQUISITOS A DATOS

Demuestre que los datos seleccionados pueden soportar cada requisito analítico e identifique las transformaciones necesarias para hacer posible ese soporte.

Requisito | Atributos requeridos | Transformación necesaria | KPI / análisis esperado

R1

R2

R3

R4

R5

Principio de diseño: No comience diseñando tablas. Primero comprenda qué necesita responder el sistema analítico.

9. ESTRATEGIA DE PREPARACIÓN DE DATOS

Defina una estrategia de preparación justificada con base en los hallazgos del perfilado y los requisitos analíticos. Puede incluir:

- Conversión de tipos de datos.
- Tratamiento de valores faltantes.
- Análisis y tratamiento de duplicados.
- Lectura y estandarización de fechas.
- Armonización de categorías.
- Estandarización de identificadores y textos.
- Tratamiento de valores inválidos o inconsistentes.
- Creación de atributos derivados únicamente cuando estén justificados por los requisitos.

No necesariamente debe modificarse cada problema detectado. Cada decisión de preparación debe justificarse según su impacto en los requisitos analíticos y el modelo dimensional.

10. DECLARAR EL GRANO

El grano declarado debe describir el evento de negocio, medición u observación representado por cada fila de la Tabla de Hechos.

Declare el grano antes de diseñar las dimensiones y los hechos. Debe ser compatible tanto con los requisitos analíticos como con los datos disponibles en la fuente.

Enunciado obligatorio: Una fila en Fact_____ representa _____.

Condición obligatoria: No se aceptará ningún modelo dimensional sin un grano declarado explícitamente.

11. MODELO DE DATOS DIMENSIONAL

Diseñe un modelo dimensional que incluya:

- Al menos una Tabla de Hechos.

- Las Tablas de Dimensiones requeridas por el grano declarado y R1-R5.
- Claves sustitutas (surrogate keys).
- Relaciones explícitas de clave primaria y clave foránea.
- Medidas y atributos descriptivos.
- Un diagrama de Esquema Estrella.

Justificación analítica: Cada dimensión, hecho, medida y atributo relevante debe tener una justificación analítica. No cree dimensiones simplemente porque existen columnas categóricas en el conjunto de datos fuente.

12. VALIDACIÓN DE REQUISITOS AL MODELO

Requisito | Dimensión(es) | Medida(s) | Consulta/KPI esperado | ¿Soportado?

R1 | | | | Sí / No

R2 | | | | Sí / No

R3 | | | | Sí / No

R4 | | | | Sí / No

R5 | | | | Sí / No

Regla de validación: Si un requisito no puede responderse mediante el modelo propuesto, revise el modelo antes de implementarlo.

13. PIPELINE ETL

Implemente un pipeline ETL reproducible en Python con responsabilidades claramente separadas.

EXTRAER

- Leer o adquirir la fuente.
- Conservar los datos sin procesar (raw).
- Documentar la adquisición.
- No realizar transformaciones de negocio durante la extracción.

TRANSFORMAR — PREPARACIÓN DE DATOS

- Limpiar y estandarizar los datos.
- Corregir los tipos de datos.
- Preparar fechas, categorías e identificadores.
- Crear atributos derivados únicamente cuando estén justificados.

TRANSFORMAR — TRANSFORMACIÓN DIMENSIONAL

- Crear dimensiones y eliminar miembros duplicados de las dimensiones cuando sea necesario.
- Generar claves sustitutas y mapear los identificadores de la fuente hacia ellas.
- Crear la Tabla de Hechos de acuerdo con el grano declarado.
- Incluir únicamente hechos y relaciones justificados por los requisitos.

VALIDAR

- Comprobar cantidades de filas, valores nulos críticos, unicidad, restricciones PK/FK e integridad referencial.
- Comprobar rangos relevantes y reglas de negocio.
- Realizar una conciliación básica con la fuente.

CARGAR

- Crear el esquema del Data Warehouse.
- Cargar primero las dimensiones y después la Tabla de Hechos.
- Verificar la integridad referencial después de la carga.

14. TECNOLOGÍA DE BASE DE DATOS

Tecnología requerida: Implemente el Data Warehouse utilizando PostgreSQL o MySQL. No se permiten otras tecnologías de base de datos salvo que hayan sido aprobadas previamente.

15. CONSULTAS ANALÍTICAS Y KPI

Implemente al menos una consulta SQL analítica para cada requisito R1–R5 y defina la métrica o KPI correspondiente cuando aplique. Resuma el resultado principal.

Requisito | Consulta analítica | Métrica o KPI | Tablas del DW utilizadas | Resultado principal

R1

R2

R3

R4

R5

Fuente obligatoria: Todas las consultas analíticas deben utilizar el Data Warehouse. Las consultas contra el archivo fuente sin procesar o DataFrames intermedios no cumplen este requisito.

16. INTELIGENCIA DE NEGOCIOS

Construya un dashboard analítico o informe de BI en Power BI, Tableau, Looker Studio cuando se haya implementado una conexión viable con la base de datos, u otra herramienta de BI aprobada por el instructor. La solución de BI debe conectarse al Data Warehouse de PostgreSQL o MySQL y no debe leer directamente el archivo fuente.

Cuando corresponda, el dashboard debe incluir:

- Análisis temporal.
- Análisis geográfico o territorial.
- Análisis comparativo.
- KPI y medidas relevantes.
- Filtros útiles.

Condición de BI: Las bibliotecas de visualización de Python no cumplen el requisito de BI.

17. INTERPRETACIÓN ANALÍTICA

Documente al menos tres hallazgos relevantes. Para cada hallazgo, explique:

- ¿Qué muestran los datos?
- ¿Qué requisito aborda?
- ¿Por qué el hallazgo es relevante en el contexto colombiano?
- ¿Qué decisión o investigación adicional podría apoyar?

18. TECNOLOGÍAS

Utilice las siguientes tecnologías:

- Python y Pandas.
- Jupyter Notebook para el perfilado inicial.
- SQL.
- PostgreSQL o MySQL.
- Power BI, Tableau, Looker Studio u otra herramienta de BI aprobada.
- Git y GitHub.

Este proyecto sigue un enfoque ETL: las transformaciones requeridas deben realizarse antes de cargar el modelo analítico en el Data Warehouse.

19. ARQUITECTURA DEL SISTEMA

Diseñe un diagrama de arquitectura de alto nivel que muestre los componentes principales y el flujo de datos de la solución analítica propuesta. Por ejemplo:

Conjunto de datos fuente → Extracción → Perfilado/Preparación de datos → Transformación dimensional → Data Warehouse PostgreSQL/MySQL → SQL/KPI → BI → Información para el negocio

La arquitectura debe representar componentes y flujo de datos, no código de implementación.

20. REPOSITORIO DE GITHUB

Se recomienda la siguiente estructura de repositorio. Se aceptan estructuras equivalentes siempre que las responsabilidades permanezcan claras.

```
etl-project-first-delivery/  
├─ data/  
│   └─ raw/  
│       └─ processed/  
├─ notebooks/  
│   └─ data_profiling.ipynb  
├─ src/  
│   └─ extract.py  
│   └─ transform.py  
│   └─ validate.py  
│   └─ dimensional_model.py  
│   └─ load.py  
│       └─ main.py  
├─ sql/  
│   └─ create_dw.sql  
│       └─ analytical_queries.sql  
├─ docs/  
│   └─ architecture.png  
│   └─ star_schema.png  
│       └─ dashboard.png  
├─ README.md  
├─ requirements.txt  
└─ .gitignore
```

Conjunto de datos grande: Proporcione la URL exacta de la fuente e instrucciones reproducibles de adquisición en lugar de obligar a incluir el conjunto de datos sin procesar dentro del repositorio.

21. README

El README debe funcionar como documentación técnica del proyecto e incluir:

- Título del proyecto, ODS seleccionado y problema colombiano.
- Objetivo analítico, partes interesadas y R1-R5.
- Alineación con los ODS.
- Fuente del conjunto de datos, propietario, enlace, instrucciones de adquisición y evaluación de idoneidad.
- Trazabilidad requisitos-datos y hallazgos del perfilado.
- Estrategia de preparación de datos.
- Arquitectura del sistema, proceso de negocio y grano.
- Esquema Estrella y justificación de dimensiones y hechos.
- Proceso ETL y reglas de validación.
- Implementación del Data Warehouse e instrucciones para reproducirlo/ejecutarlo.
- Consultas analíticas/KPI y evidencia del dashboard de BI.
- Hallazgos principales, limitaciones y supuestos.
- Integrantes del equipo y responsabilidades.

21. ENTREGA

Entrega: Envíe ÚNICAMENTE la URL del repositorio de GitHub a través del LMS. Toda la evidencia y documentación debe estar organizada dentro del repositorio; no se requiere un informe PDF separado.

22. PRESENTACIÓN Y DEFENSA

El equipo presentará y defenderá la solución analítica implementada. Cada integrante debe comprender el problema, los requisitos, el conjunto de datos, el perfilado, el grano, el modelo dimensional, el ETL, SQL, el Data Warehouse, la solución de BI y los hallazgos.

Dominio individual: Durante la presentación, se puede pedir a cualquier integrante que explique cualquier componente de la solución implementada.

Demostración: El instructor puede solicitar la ejecución o demostración de componentes seleccionados de la solución.

23. EVALUACIÓN

La calificación final de esta entrega se distribuye de la siguiente manera:

REPOSITORIO DE GITHUB

- Problema colombiano, alineación con ODS, objetivo y R1-R5: 10%
 - Selección del conjunto de datos, evaluación de idoneidad y perfilado: 10%
 - Trazabilidad requisitos-datos y requisitos-modelo: 5%
 - Grano y modelado dimensional: 15%
 - Implementación y validación ETL: 15%
 - Implementación del Data Warehouse PostgreSQL/MySQL: 8%
 - Consultas SQL y KPI: 5%
 - Dashboard de BI e interpretación analítica: 10%
 - Reproducibilidad, organización del repositorio y documentación: 2%
- Subtotal repositorio de GitHub: 80%

PRESENTACIÓN Y DEFENSA

- Comprensión del problema y de la solución completa: 5%
 - Justificación de las decisiones analíticas y técnicas: 4%
 - Interpretación de los hallazgos: 4%
 - Respuesta a preguntas y dominio individual: 4%
 - Comunicación profesional: 3%
- Subtotal presentación y defensa: 20%

TOTAL: Repositorio de GitHub (80%) + Presentación y defensa (20%) = 100%.